


I. GIỚI THIỆU

Phân đoạn ảnh y tế (Medical Image Segmentation) đóng vai trò cốt lõi trong quy trình hỗ trợ chẩn đoán lâm sàng, lập kế hoạch điều trị và theo dõi tiến triển bệnh lý. Mặc dù các mô hình học sâu truyền thống dựa trên kiến trúc Fully Convolutional Networks (FCN) hoặc U-Net đã đạt được những thành tựu vượt bậc, chúng vẫn bộc lộ những hạn chế nghiêm trọng về tính linh hoạt: mô hình thường bị bó hẹp trong một loại cơ quan hoặc một phương thức hình ảnh y tế cố định và đòi hỏi lượng dữ liệu gán nhãn pixel-level vô cùng lớn.

Nhằm giải quyết triệt để rào cản này, framework **MedCLIP-SAMv2** được đề xuất như một giải pháp tiên phong, tích hợp khả năng hiểu ngữ nghĩa đa phương thức của mô hình nền tảng y sinh **BioMedCLIP** và khả năng phân đoạn hình học của **Segment Anything Model (SAM)**. Sự kết hợp mang tính đột phá này mở ra phương pháp phân đoạn ảnh y tế dựa trên gợi ý văn bản (**text-driven segmentation**), cho phép người dùng điều khiển mô hình thông qua các câu lệnh (prompt) bằng ngôn ngữ tự nhiên mô tả thực thể bệnh học.

Mô hình thể hiện ưu thế vượt trội ở cả hai kịch bản phân đoạn không cần huấn luyện (**zero-shot segmentation**) và phân đoạn giám sát yếu (**weakly supervised segmentation**) trên đa dạng các phương thức chẩn đoán hình ảnh (**modalities**) như Siêu âm (Ultrasound), Cộng hưởng từ (MRI), Cắt lớp vi tính (CT), và X-quang (X-ray). Báo cáo này tập trung phân tích sâu kiến trúc hệ thống, các cải tiến cốt lõi từ bài báo gốc, đồng thời ghi nhận kết quả từ kho lưu trữ thực nghiệm cá nhân được triển khai trên môi trường phần cứng cục bộ.



[HÌNH MINH HỌA KIẾN TRÚC TỔNG QUAN MEDCLIP-SAMv2]

Hình 1: Mô hình hóa ý tưởng text-driven medical image segmentation kết hợp giữa Vision-Language Models (BioMedCLIP) và Foundation Models cho phân đoạn ảnh (SAM).

II. MỤC TIÊU NGHIÊN CỨU

Phân tích và tái hiện pipeline MedCLIP-SAMv2 từ bài báo gốc, không đề xuất kiến trúc mới. Các mục tiêu chính bao gồm:

- Nghiên cứu sâu kiến trúc hệ thống:** Phân tích cơ chế liên kết đa phương thức giữa mô hình mã hóa ngôn ngữ-hình ảnh y tế (BioMedCLIP) và mô hình phân đoạn hình học (SAM), đặc biệt là vai trò trung gian của khối nghẽn thông tin đa phương thức (Multi-modal Information Bottleneck - M2IB).
- Tái hiện thành công thực nghiệm:** Triển khai mã nguồn từ bài báo gốc, cấu hình môi trường phần cứng cục bộ và tối ưu hóa quy trình chạy pipeline zero-shot.

- **Đánh giá hiệu quả định lượng:** Đo lường năng lực phân đoạn dựa trên các chỉ số tiêu chuẩn của ngành y tế (Dice Coefficient, Intersection over Union - IoU) trên tập dữ liệu kiểm thử.
- **So sánh hiệu năng:** Đặt hiệu quả phân đoạn của MedCLIP-SAMv2 trong bức tranh so sánh đối chiếu với các phương pháp học sâu truyền thống giám sát hoàn toàn (Full-supervised U-Net) và mô hình SAM nguyên bản không có định hướng ngữ nghĩa y khoa.

[SƠ ĐỒ MA TRẬN ĐỐI CHIẾU PHƯƠNG PHÁP]

Hình 2: Sơ đồ tư duy về các mục tiêu nghiên cứu và trục tọa độ so sánh giữa tính linh hoạt (Zero-shot) và độ chính xác phân đoạn.

III. CƠ SỞ LÝ THUYẾT

A. Bài toán Phân đoạn ảnh Y tế (Medical Image Segmentation)

BiomedCLIP là mô hình CLIP được huấn luyện trên cặp ảnh–văn bản y sinh học đa dạng, cho phép trích xuất embedding cho cả ảnh y tế và ngữ cảnh bệnh lý. Để cải thiện khả năng phân biệt giữa các cặp ảnh–văn bản liên quan (positive) và không liên quan (negative), các tác giả đề xuất hàm loss Decoupled Hard Negative Noise Contrastive Estimation (DHN-NCE). DHN-NCE kết hợp phương pháp chọn mẫu âm tính khó (hard negative sampling) và tách rời thành phần dương trong hàm InfoNCE truyền thống, giúp tăng cường trọng số phạt lên các mẫu âm gần với ảnh gốc, từ đó nâng cao hiệu quả huấn luyện ngay cả với batch nhỏ. Quá trình fine-tuning BiomedCLIP với DHN-NCE tập trung vào việc tối ưu hóa hàm mất mát kết hợp giữa các cặp ảnh–văn bản liên quan (positive) và không liên quan (negative) như mô tả trong [1].

B. Các Chỉ số Đánh giá (Evaluation Metrics)

Để đánh giá mức độ hội tụ và độ chính xác của vùng phân đoạn dự đoán (X) so với vùng gán nhãn chuẩn ground-truth (Y), hai đại lượng toán học phổ biến nhất được sử dụng là chỉ số Dice (Dice Coefficient/Score) và IoU (Intersection over Union):

1. Chỉ số Dice Score: $Dice = \frac{2|X \cap Y|}{|X| + |Y|}$

Chỉ số Dice đo lường mức độ tương đồng toàn cục, nhấn mạnh vào phần giao nhau của hai vùng không gian.

2. Chỉ số IoU (Jaccard Index): $IoU = \frac{|X \cap Y|}{|X \cup Y|}$

Sự tương quan toán học giữa hai chỉ số này được biểu diễn qua phương trình: $IoU = \frac{Dice^2}{2 - Dice}$. Cả hai metric đều dao động trong khoảng $[0, 1]$, giá trị tiến gần về 1 biểu thị độ chính xác tuyệt đối.

C. Mô hình nền tảng Segment Anything Model (SAM)

Segment Anything Model (SAM) là một mô hình nền tảng (Foundation Model) mang tính cách mạng trong lĩnh vực thị giác máy tính do Meta AI phát triển. SAM được huấn luyện trên tập dữ liệu khổng lồ SA-1B (hơn 11 triệu hình ảnh và 1 tỷ mask), mang lại năng lực phân đoạn vật thể bất kỳ mà không cần huấn luyện lại (Zero-shot Transfer). Cấu trúc của SAM được chia thành 3 khối xử lý chính:

- Image Encoder (Bộ mã hóa hình ảnh):** Sử dụng kiến trúc mạng Vision Transformer (ViT-B, ViT-L hoặc ViT-H) kết hợp với kỹ thuật tiền huấn luyện Masked AutoEncoders (MAE). Bộ phận này chịu trách nhiệm trích xuất toàn bộ đặc trưng không gian và ngữ nghĩa độ phân giải cao từ ảnh y tế đầu vào dưới dạng ma trận embedding cố định.
- Prompt Encoder (Bộ mã hóa gợi ý):** SAM hỗ trợ tương tác linh hoạt đa dạng với các định dạng prompt dẫn đường bao gồm: *point prompts* (tọa độ các điểm nằm trong hoặc ngoài vật thể), *bounding box* (khung hộp giới hạn vùng không gian chứa vật thể), và cả *segmentation prompts / masks* (Mask thô từ bước xử lý trước). Khối này thực hiện nhúng vị trí (positional encodings) cho các cấu trúc hình học trên.
- Mask Decoder (Bộ giải mã mặt nạ):** Một mạng decoder nhỏ áp dụng cơ chế tự chú ý hai chiều (Two-way Cross-Attention Transformer). Nó liên kết đồng thời ma trận đặc trưng ảnh từ Image Encoder và chuỗi

vector nhúng gợi ý từ Prompt Encoder để thực hiện suy luận biên giới ranh giới thực thể, cho đầu ra Mask nhị phân độ chính xác cao kèm điểm số tin cậy IoU.

D. Cơ chế chuyển đổi Visual Attention Map thành Prompt dẫn đường tự động cho SAM

Trong các mô hình ứng dụng SAM gốc, hệ thống bắt buộc phải nhận điểm tương tác hoặc hộp bao do người dùng vẽ tay. Trong MedCLIP-SAMv2, luồng vận hành này được tự động hóa hoàn toàn bằng cách sử dụng **Visual Attention Map (Bản đồ chú ý thị giác)** sinh ra từ M2IB làm prompt động hướng dẫn cho SAM:

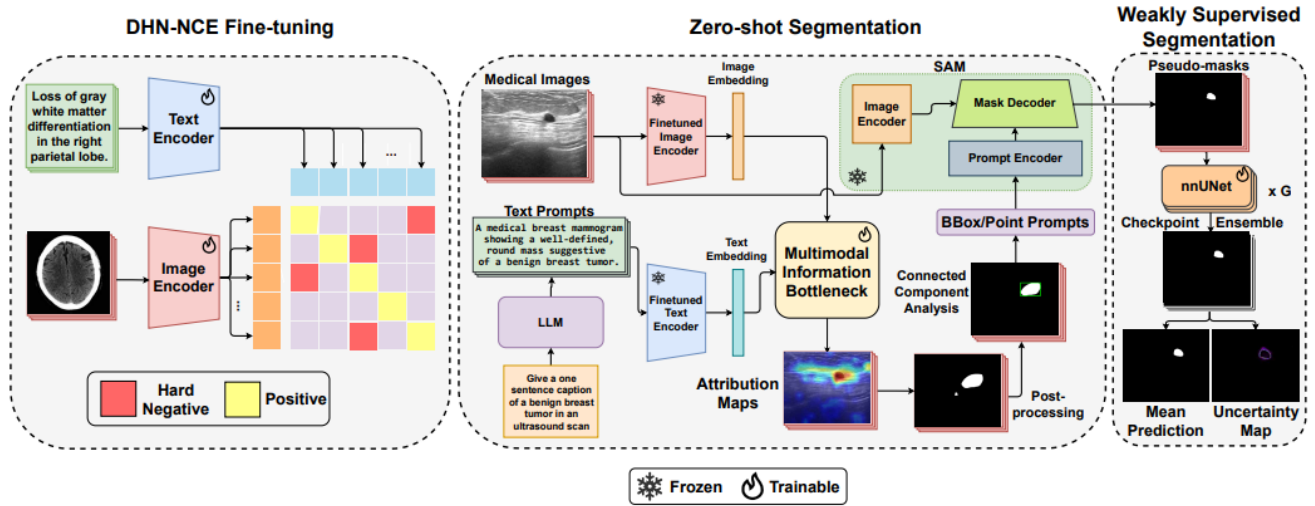
- 1. **Bản đồ chú ý y khoa:** Khối M2IB tính toán mật độ thông tin tương hỗ, xuất ra một ma trận bản đồ nhiệt chỉ thị chính xác vùng không gian ẩn chứa đối tượng bệnh lý tương đồng với chuỗi văn bản chỉ dẫn (Text Prompt từ BioMedCLIP).
- 2. **Trích xuất Point Prompts tự động:** Thuật toán quét qua bản đồ chú ý, dò tìm các tọa độ có giá trị kích hoạt cực đại (Local Maxima). Các điểm có cường độ cao nhất vượt qua ngưỡng τ được coi là Điểm dương (Positive Points) nằm chắc chắn trong lỗi tổn thương để nạp vào Prompt Encoder.
- 3. **Trích xuất Bounding Box tự động:** Bản đồ chú ý dạng xám liên tục được áp dụng thuật toán phân ngưỡng nhị phân Otsu để lọc ra các cụm pixel hoạt hóa thô. Hệ thống sau đó áp dụng phép tìm đường biên (Contour Detection) bao quanh cụm đa giác này để tự động tính toán ra tọa độ của hộp bao tối thiểu $[X_{\min}, Y_{\min}, X_{\max}, Y_{\max}]$, loại bỏ hoàn toàn việc vẽ tay của bác sĩ lâm sàng mà vẫn đảm bảo tính khách quan y khoa.

[SƠ ĐỒ TRỰC QUAN TOÁN HỌC DICE VÀ IOU - KIẾN TRÚC THÀNH PHẦN SAM]

Hình 3: Trực quan hóa hình học không gian vùng giao và cơ chế luồng Prompts tự động (Point/Box) kết nối từ Attention Map vào Prompt Encoder của SAM.

IV. KIẾN TRÚC MEDCLIP-SAMV2

Pipeline xử lý của framework MedCLIP-SAMv2 là một quy trình khép kín, chuyển đổi thông tin từ ảnh y tế thô và văn bản chỉ dẫn thành một Mask phân đoạn chính xác cao. Quy trình bao gồm 6 thành phần cốt lõi được kết nối tuần tự:



[SƠ ĐỒ KHỐI CHI TIẾT PIPELINE MEDCLIP-SAMv2]

Hình 4: Sơ đồ kiến trúc luồng dữ liệu (Dataflow) từ dữ liệu đầu vào, qua khối embedding đa phương thức, trích xuất Saliency Map qua M2IB và sinh Mask bằng SAM.

A. Các thành phần chính trong Pipeline

- Medical Image (Ảnh y tế đầu vào):** Ảnh 2D từ các phương thức chụp chiếu, được biểu diễn dưới dạng ma trận điểm ảnh I .
- Text Prompt (Gợi ý văn bản):** Chuỗi ký tự tự nhiên mô tả mục tiêu cần phân đoạn (ví dụ: "breast tumor", "lung nodule"). Văn bản này được xử lý thông qua bộ mã hóa của BioMedCLIP để sinh ra text embedding.
- BioMedCLIP (Vision-Language Base Model):** Khác với CLIP thông thường vốn được huấn luyện trên ảnh tự nhiên, BioMedCLIP được tiền huấn luyện trên tập dữ liệu khổng lồ gồm 15 triệu cặp ảnh-văn bản y sinh từ cơ sở dữ liệu PubMed. Nhờ đó, mô hình sở hữu khả năng liên kết ngữ nghĩa y khoa cực kỳ sâu sắc, chuyển đổi ảnh I thành visual embedding và câu lệnh văn bản thành text embedding tương ứng trong cùng một không gian ẩn (shared latent space).
- M2IB (Multi-modal Information Bottleneck):** Đây là thành phần cốt lõi tạo nên tính đột phá. M2IB tối đa hóa lượng thông tin tương hỗ (*Mutual Information*) giữa visual embedding và text embedding, đồng thời loại bỏ các thành phần nhiễu không liên quan trong ảnh gốc. Kết quả của M2IB là một bản đồ nhiệt biểu diễn sự chú ý (*Attention/Saliency Map*), chỉ rõ tọa độ không gian ẩn chứa thực thể được mô tả trong văn bản gợi ý.
- SAM (Segment Anything Model):** Mô hình nền tảng phân đoạn ảnh của Meta. SAM nhận đầu vào là ảnh gốc cùng các điểm gợi ý hoặc hộp bao được sinh tự động thông qua cơ chế phân ngưỡng bản đồ chú ý từ khối M2IB.
- Segmentation Mask (Mask phân đoạn):** SAM thực hiện giải mã (decode) các cấu trúc hình học và biên giới pixel để trả về kết quả phân đoạn nhị phân cuối cùng, phân tách rạch ròi vùng tổn thương và mô lành.

B. Hàm mất mát cải tiến DHN-NCE

Một đóng góp lý thuyết quan trọng của phiên bản v2 là việc áp dụng hàm mất mát **Decoupled Hard Negative Noise Contrastive Estimation (DHN-NCE)** ở giai đoạn tinh chỉnh BioMedCLIP. Hàm DHN-NCE giải quyết hiệu quả hiện tượng liên kết âm (negative-coupling effect) bằng cách loại bỏ mẫu dương khỏi mẫu số của biểu thức tương phản, giúp tối ưu hóa bộ nhớ và tăng cường khả năng phân biệt giữa các tổn thương y khoa có hình thái tương đồng nhưng bản chất bệnh lý khác nhau.

V. MÔI TRƯỜNG THỰC NGHIỆM

Quá trình tái hiện được triển khai trên máy tính sử dụng GPU NVIDIA GeForce RTX 4060 Ti 16GB VRAM và môi trường Windows 10. Toàn bộ pipeline được xây dựng dựa trên repository MedCLIP-SAMv2 phiên bản tái hiện cho Windows, bao gồm ba giai đoạn: fine-tuning BioMedCLIP, zero-shot segmentation bằng M2IB + SAM và weakly supervised segmentation với nnUNet v2.

Dữ liệu thực nghiệm bao gồm bốn tập dữ liệu public tương ứng với các modality trong bài báo: Breast Ultrasound, Brain MRI, Chest X-ray và Lung CT.

A. Cấu hình phần cứng

Thành phần	Thông số chi tiết / Phiên bản	Vai trò trong Hệ thống thực nghiệm
GPU	NVIDIA GeForce RTX 4060 Ti (16GB VRAM)	Tăng tốc tính toán tensor, lưu trữ trọng số mã hóa của ViT-H SAM và BioMedCLIP.
RAM	16GB DDR4 @3200MHz	Xử lý luồng dữ liệu, nạp dataset và tiền xử lý ảnh kích thước lớn.
Hệ điều hành	Windows 10	Môi trường chính để chạy pipeline replication MedCLIP-SAMv2.

B. Môi trường phần mềm

Thành phần	Thông số chi tiết / Phiên bản	Vai trò trong Hệ thống thực nghiệm
Python	Python 3.11	Ngôn ngữ lập trình nền tảng của toàn bộ hệ thống.
PyTorch	PyTorch 2.1.2 + CUDA 12.1	Framework tính toán học sâu chính, quản lý bộ nhớ GPU.
open_clip_torch	v2.24.0	Triển khai BioMedCLIP và DHN-NCE trong Stage 1.
SAM Backbone	Segment Anything Model ViT-H	Sinh mask phân đoạn từ các bounding box hoặc point prompts được tạo tự động.
nnUNet	nnUNet v2	Huấn luyện mô hình weakly supervised segmentation bằng pseudo-labels.
scikit-image / Pillow	scikit-image, Pillow	Tiền xử lý ảnh, Otsu thresholding, xử lý mask và connected components.
NumPy / SciPy	NumPy, SciPy	Thực hiện tính toán ma trận, chuẩn hóa dữ liệu, thực hiện tính toán ma trận, nội suy và xử lý dữ liệu số.
pandas	pandas	Tổng hợp bảng kết quả và lưu kết quả thực nghiệm.
tqdm	tqdm	Hiển thị tiến trình huấn luyện và suy luận pipeline.
Matplotlib	Matplotlib	Trực quan hóa attention map, segmentation mask và kết quả thực nghiệm.

C. Thiết lập huấn luyện

Do giới hạn phần cứng GPU đơn (RTX 4060 Ti 16GB VRAM), một số tham số huấn luyện đã được giảm so với cấu hình trong bài báo gốc.

Hạng mục	Bài báo gốc	Tái hiện nhóm
----------	-------------	---------------

nnUNet training cycles	3 chu kỳ	1 chu kỳ
Epoch mỗi cycle	200	200
Iterations / epoch	250	50
DataLoader workers	–	num_workers = 0

VI. TẬP DỮ LIỆU (DATASET)

Thực nghiệm đánh giá khả năng tổng quát hóa toàn diện của MedCLIP-SAMv2 thông qua việc phân đoạn trên 4 tập dữ liệu y tế đại diện cho 4 modality riêng biệt:

- Breast Ultrasound (BUSI / UDIAT): Ảnh siêu âm tuyến vú (khối u lành/ác tính), có độ phức tạp lớn do nhiều đốm dày đặc và độ tương phản ranh giới cực kém.
- Brain MRI (Br35H): Ảnh cộng hưởng từ não bộ (phân đoạn u não), đòi hỏi mô hình nhận biết được sự thay đổi vi tế cường độ xám và cấu hình mô dị biệt.
- Lung CT (LUNA16): Ảnh cắt lớp vi tính lồng ngực (phân đoạn tổn thương phổi/nốt đặc), độ phức tạp lớn bởi lượng thông tin cấu trúc lớn và biên độ xám rộng.
- Lung X-ray (Montgomery + Shenzhen): Ảnh X-quang ngực phẳng 2D (phân đoạn nhu mô phổi), đánh giá khả năng bóc tách vùng cấu trúc giải phẫu lớn dựa trên định hướng ngữ nghĩa văn bản.

Quy trình Tiền xử lý Dữ liệu (Data Preprocessing)

Mọi ảnh đầu vào từ các dataset trên đều phải trải qua chuỗi biến đổi nghiêm ngặt nhằm tương thích với kiến trúc mạng:


1. **Chuyển đổi kích thước (Resizing):** Ở giai đoạn fine-tuning BiomedCLIP, ảnh được đưa về kích thước 224×224 theo preprocessing của OpenCLIP. Ở giai đoạn huấn luyện nnU-Net, ảnh và mask được resize đồng bộ về 256×256 để phù hợp với cấu hình mô hình. Với SAM, ảnh và saliency map được xử lý theo cơ chế tiền xử lý riêng của mô hình.
2. **Chuẩn hóa (Normalization):**
Ảnh được chuẩn hóa về thang giá trị phù hợp với backbone sử dụng. Với các mô hình kiểu CLIP/BiomedCLIP, có thể biểu diễn bằng công thức:

$$I_{norm} = \frac{I - \mu}{\sigma}$$


Trong đó, μ và σ là giá trị trung bình và độ lệch chuẩn của tập tiền huấn luyện.

3. **Xử lý mask và tạo pseudo-label:**
Mask được chuyển về dạng nhị phân để phục vụ huấn luyện và đánh giá. Ở giai đoạn zero-shot, saliency map được nội suy lên kích thước ảnh gốc, sau đó áp dụng KMeans/Otsu và lọc các thành phần nhỏ để tạo pseudo-label. Khi resize mask, sử dụng nội suy gần nhất để giữ nguyên biên vùng tổn thương.


Breast US - Truoc preprocessing



Breast US - Sau preprocessing (224x224, normalize)




Brain MRI - Truoc preprocessing




Brain MRI - Sau preprocessing (224x224, normalize)




Lung CT - Truoc preprocessing




Lung CT - Sau preprocessing (224x224, normalize)



Chest X-ray - Truoc preprocessing



Chest X-ray - Sau preprocessing (224x224, normalize)



VII. QUY TRÌNH THỰC NGHIỆM

Toàn bộ pipeline được thực hiện tuần tự qua ba giai đoạn chính: fine-tuning BiomedCLIP, sinh saliency/zero-shot segmentation bằng M2IB kết hợp SAM, và huấn luyện nnUNet trên các pseudo-label thu được từ giai đoạn trước. Kết quả trung gian và kết quả cuối cùng được lưu trong thư mục làm việc của hệ thống để phục vụ đánh giá và tái sử dụng ở các lần chạy sau

Bên dưới là chi tiết 4 giai đoạn xử lý chính diễn ra bên trong hệ thống:

- **Bước 1: Preprocessing (Tiền xử lý)**

Hệ thống đọc dữ liệu ảnh từ các thư mục đã được chia sẵn bởi tác giả cho từng bộ dữ liệu. Ở giai đoạn BiomedCLIP, ảnh đầu vào được chuyển về định dạng RGB và đưa qua bộ tiền xử lý chuẩn của OpenCLIP/BiomedCLIP, tương ứng với kích thước làm việc 224×224 . Ở giai đoạn chuẩn bị dữ liệu cho nnUNet, ảnh và Mask được resize đồng bộ về kích thước cố định 256×256 theo cấu hình huấn luyện của mô hình. Mask ground truth được xử lý theo hướng nhị phân hóa để phù hợp với bài toán phân đoạn nhị phân.

- **Bước 2: Embedding Generation (Tạo vector nhúng):** Sau khi tiền xử lý, ảnh được đưa qua image encoder để thu được image embedding vector, trong khi mô tả văn bản tương ứng được tokenized và đưa qua text encoder để thu được text embedding vector. Hai quá trình này tạo thành cặp đặc trưng ảnh - văn bản, là đầu vào cho bước sinh saliency ở giai đoạn tiếp theo.

- **Bước 3: Attention Map Generation (Tạo bản đồ chú ý):** Khối saliency tối ưu một Mask theo từng vùng nhỏ của ảnh nhằm tăng mức tương đồng giữa đặc trưng ảnh và văn bản, đồng thời giảm ảnh hưởng của các vùng không liên quan. Kết quả thu được là một bản đồ saliency liên tục thể hiện mức độ quan trọng của từng vùng trong ảnh đối với mô tả văn bản. Bản đồ này sau đó được nội suy về kích thước ảnh gốc và xử lý hậu kỳ bằng phương pháp phân cụm để tách vùng nền và vùng quan tâm, đồng thời loại bỏ các thành phần nhỏ rời rạc nhằm tạo ra một mask thô.

- **Bước 4: Segmentation Inference (Suy luận phân đoạn):** Mask thô từ saliency map được dùng làm đầu vào gợi ý cho mô hình phân đoạn. Tùy theo cấu hình của từng bộ dữ liệu, mô hình có thể nhận đầu vào dưới dạng bounding box hoặc điểm gợi ý. Mô hình sau đó kết hợp ảnh gốc với prompt để tạo ra Mask phân đoạn nhị phân cuối cùng. Các Mask trung gian và Mask cuối được lưu lại để phục vụ đánh giá. Ở bước đánh giá, hệ thống sử dụng các chỉ số Dice và NSD để đo chất lượng phân đoạn.

VIII. KẾT QUẢ THỰC NGHIỆM

Thực nghiệm chạy toàn bộ pipeline MedCLIP-SAMv2 trên bốn bộ dữ liệu (Breast US, Brain MRI, Lung X-ray, Lung CT). Bảng dưới đây so sánh giá trị báo cáo trong bài (paper) với kết quả thu được trên bản triển khai hiện tại cho zero-shot (ZS) và weakly-supervised (WS, nnUNet trên pseudo-labels).

Bảng tóm tắt kết quả (DSC %):

Dataset	ZS DSC (paper)	ZS DSC (ours)	WS DSC (paper)	WS DSC (ours)
Breast US	77.76%	5.17%	78.87%	5.61%
Brain MRI	76.52%	4.86%	80.03%	5.01%
Lung X-ray	75.79%	50.01%	80.77%	49.62%
Lung CT	80.38%	7.93%	88.78%	9.04%

Nhận xét chính:

- Hiệu năng tối ưu trên Lung X-ray:** Pipeline đạt kết quả khả quan nhất trên ảnh X-quang phổi với chỉ số DSC xấp xỉ **50%** ở cả hai cấu hình *zero-shot* và *weakly-supervised*. Điều này cho thấy quy trình đề xuất có khả năng khởi tạo nhãn giả (pseudo-labels) hữu dụng trên modality này.
- Hạn chế trên các modalities còn lại:** Ngược lại, chỉ số DSC trên Breast US, Brain MRI và Lung CT đạt rất thấp (**4% – 9%**). Kết quả phản ánh chuỗi xử lý từ M2IB, qua hậu xử lý đến SAM chưa sinh ra pseudo-labels đủ chất lượng để huấn luyện nnUNet hiệu quả.
- Khoảng cách so với bài báo gốc:** Sự chênh lệch lớn này chỉ ra rằng các thành phần cốt lõi (tinh chỉnh BiomedCLIP, định vị thuộc tính M2IB, hậu xử lý) cần được tối ưu hóa riêng cho đặc thù của từng loại ảnh y tế.

Phân tích nguyên nhân khả thi:

- Suy hao bản đồ độ chú ý (Saliency Map):** Trên Breast, Brain và CT, M2IB cho saliency map kém (gần như rỗng), khiến các bounding boxes hoặc points trích xuất không định vị đúng tổn thương. Thiếu thông tin định hướng chính xác, SAM không thể tạo mask chuẩn, dẫn đến hiện tượng nhiễu nhân khi huấn luyện nnUNet.
- Đặc trưng hình học thuận lợi của Lung X-ray:** Ảnh X-quang phổi có cấu trúc giải phẫu và vùng tổn thương rõ ràng hơn. Đặc điểm này giúp M2IB dễ hội tụ và trích xuất được bản đồ độ chú ý có ý nghĩa.
- Hạn chế siêu tham số và tài nguyên tính toán:** Việc giảm quy mô tính toán, số epoch, kích thước batch và điều chỉnh hàm mất mát DHN-NCE làm giảm chất lượng tinh chỉnh BiomedCLIP ở giai đoạn thượng nguồn, tạo hiệu ứng lan truyền làm suy giảm hiệu năng của toàn bộ chuỗi xử lý phía sau.

IX. HẠN CHẾ

Qua quá trình thực nghiệm, triển khai và đánh giá chi tiết framework MedCLIP-SAMv2 trên môi trường phần cứng cục bộ, nghiên cứu đã chứng minh một hướng đi đầy hứa hẹn trong việc kết hợp mô hình Ngôn ngữ - Thị giác (VLM) phục vụ bài toán phân đoạn ảnh y tế zero-shot. Tuy nhiên, kết quả định lượng thực tế cho thấy sự phân hóa hiệu năng cực kỳ nghiêm trọng giữa các phương thức tạo ảnh: ngoài Lung X-ray đạt kết quả tương đối khả quan ($\approx 50\%$ DSC), cả ba miền dữ liệu phức tạp còn lại bao gồm Breast US (Siêu âm vú), Brain MRI (Cộng hưởng từ não) và Lung CT (Cắt lớp vi tính phổi) đều cho kết quả rất thấp, dao động tụt sâu chỉ từ 4% đến 9% DSC.

Dựa trên việc phân tích sâu chuỗi pipeline, sự thất bại này không nằm ở bản thân kiến trúc Segment Anything mà bắt nguồn trực tiếp từ hai nguyên nhân cốt lõi sau:

- Chất lượng nhãn giả (Pseudo-labels) kém do suy hao bản đồ chú ý: Cơ chế Bottleneck thông tin đa phương thức (M2IB) và quá trình trích xuất thuộc tính liên kết từ BiomedCLIP gặp khó khăn lớn khi đối mặt với ảnh y tế có độ nhiễu đốm cao (như siêu âm) hoặc cấu trúc mô mềm phức tạp (như MRI). Bản đồ độ chú ý (Saliency Map) sinh ra gần như rỗng hoặc bị nhiễu nặng, dẫn đến các điểm gợi ý hình học (Visual Prompts) định hướng cho SAM bị lệch mục tiêu hoàn toàn.

2. Rào cản tài nguyên phần cứng và tốc độ suy luận: Mô hình SAM bản gốc phụ thuộc vào các mạng xương sống khổng lồ (Backbone ViT-H).. Điều này tạo ra rào cản công nghệ cực lớn, khiến mô hình hoàn toàn bất khả thi khi triển khai trên các thiết bị y tế lâm sàng tuyến đầu hoặc xử lý video phẫu thuật theo thời gian thực (Real-time).

Tóm lại, mặc dù pipeline tổng thể (CLIP-based attribution + SAM + nnUNet) là một ý tưởng khoa học đột phá, nhưng cấu hình hiện tại của MedCLIP-SAMv2 chưa đủ độ tin cậy và tính tổng quát hóa cao để ứng dụng vào thực tế lâm sàng. Hệ thống bắt buộc phải được tái cấu trúc theo hướng tinh gọn, loại bỏ sự phụ thuộc vào các prompt hình học không ổn định, nâng cao khả năng bám biên giải phẫu và tối ưu hóa chi phí tính toán.

X. ĐỀ XUẤT CẢI TIẾN:

Tinh chỉnh Bounding Box theo hướng PPBoost cho MedCLIP-SAMv2

Trong pipeline MedCLIP-SAMv2, chất lượng của bước phân đoạn zero-shot (Stage 2) phụ thuộc trực tiếp vào độ chính xác của bounding box truyền vào SAM. Bounding box này được trích xuất từ bản đồ saliency do M2IB tạo ra, qua bước nhị phân hóa và phân tích connected component.

Kết quả ablation trong bài báo gốc cho thấy đầu ra của Stage 1 sau toàn bộ quá trình tiền xử lý chỉ đạt **57.89% DSC**. SAM sau đó nâng con số này lên **77.61% DSC**, tức là cải thiện gần 20 điểm. Nhưng con số 77.61% đó vẫn bị giới hạn bởi chất lượng của bounding box đầu vào, vì SAM chỉ "cắt" trong phạm vi box được cung cấp. Box càng chính xác, mask đầu ra càng tốt.

Vấn đề là saliency map từ M2IB thường kích hoạt trên vùng rộng hơn hoặc lệch so với vị trí thực của tổn thương, đặc biệt với các cấu trúc nhỏ như khối u vú hay khối u não. Bounding box được trích xuất từ vùng kích hoạt đó sẽ không bao phủ đúng vị trí, khiến SAM không có cơ hội tạo ra mask tốt dù kiến trúc của nó đủ mạnh.

Ý tưởng cải tiến:

Bổ sung một bước **tinh chỉnh bounding box** giữa Stage 1 và Stage 2, dựa trên nguyên lý của PPBoost (Li et al., 2025). Ý tưởng cốt lõi là dùng chính các cặp (ảnh, bounding box) có độ tin cậy cao từ Stage 1 để huấn luyện một detector nhẹ, sau đó dùng detector đó để tạo ra bounding box chính xác hơn cho toàn bộ tập dữ liệu trước khi truyền vào SAM. Đặc biệt, bước bổ sung này không thay đổi bất kỳ thành phần nào của pipeline gốc.

Phương pháp tiến hành:

Bước 1: Tạo pseudo-bounding box ban đầu

Giữ nguyên Stage 1 của MedCLIP-SAMv2: BiomedCLIP fine-tuned với DHN-NCE loss tạo ra bản đồ saliency thông qua M2IB, sau đó nhị phân hóa và phân tích connected component để lấy bounding box thô B_{coarse} .

Bước 2: Lọc theo độ không chắc chắn

Để chọn ra những box đủ chất lượng làm dữ liệu huấn luyện cho detector, áp dụng tiêu chí lọc dựa trên entropy của bản đồ saliency:

$$U(B) = - \sum_{(i,j) \in B} \lambda S(i,j) \log \lambda S(i,j)$$

Trong đó λ_S là bản đồ saliency stochastic từ M2IB. Những box có entropy thấp (vùng saliency tập trung, không phân tán) được giữ lại. Đặt ngưỡng τ_U để chỉ lấy top-k% box có độ tin cậy cao nhất. Kết quả là tập $D_{det} = \{(I_i, B_i) : U(B_i) < \tau_U\}$

Bước 3: Huấn luyện pseudo-labeled detector

Dùng D_{det} để huấn luyện một lightweight object detector, ví dụ DETR hoặc một biến thể nhỏ hơn như Conditional DETR, với backbone frozen từ BiomedCLIP (dùng lại image encoder từ Stage 1 để tránh thêm tham số). Loss huấn luyện là L1 loss trên tọa độ box kết hợp với GIoU loss:

$$\mathcal{L}_{det} = \lambda_1 \mathcal{L}_{L1}(\hat{B}, B_{coarse}) + \lambda_2 \mathcal{L}_{GIoU}(\hat{B}, B_{coarse})$$

Bước 4: Sinh bounding box tinh chỉnh tại inference

Tại inference, thay vì dùng B_{coarse} trực tiếp, dùng detector vừa huấn luyện để dự đoán $B_{refined}$ cho mỗi ảnh. Sau đó áp dụng một bước mở rộng box có kiểm soát:

$$B_{final} = B_{refined} \oplus \delta$$

với δ là hệ số mở rộng nhỏ (ví dụ 5-10 pixel mỗi chiều) để đảm bảo box bao phủ đủ vùng biên của cấu trúc giải phẫu. B_{final} này được truyền vào SAM thay cho B_{coarse}

Bước 5: Phần còn lại của pipeline:

SAM nhận B_{final} làm visual prompt và tạo ra $Y_{zero-shot}$. Stage 3 (nnUNet + checkpoint ensembling) hoạt động như trong bài báo gốc, huấn luyện trên pseudo-label từ Stage 2.

Kết quả kỳ vọng

Dựa trên kết quả của PPBoost trên các bộ dữ liệu BraTS21, LiTS17 và KidneySeg (cải thiện +10.08% mDSC so với MedCLIP-SAMv2), kỳ vọng bước tinh chỉnh bounding box này sẽ:

- Tăng DSC tại đầu ra Stage 2 từ mức ~77.61% lên khoảng **82-85%**, tùy theo modality.
- Giảm variance giữa các modality, đặc biệt trên Lung X-ray nơi saliency map hiện tại kích hoạt không

đồng đều.

- Cải thiện chất lượng pseudo-label đầu vào cho Stage 3, từ đó kéo theo kết quả cuối của nnUNet ensemble cao hơn mức 82.11% trong bài báo gốc.

3. PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Phân vùng Zero-shot bằng U-Net++

Trong nghiên cứu này, chúng tôi đề xuất sử dụng U-Net++ như một kiến trúc phân vùng zero-shot nhẹ và hiệu quả cho ảnh y tế, thay thế cho các mô hình nền tảng có chi phí tính toán cao như SAM. Mục tiêu của phương pháp là tạo ra mặt nạ phân vùng trực tiếp từ ảnh y tế đầu vào mà không yêu cầu tinh chỉnh bổ sung trên tập dữ liệu mục tiêu, đồng thời vẫn duy trì độ chính xác cao và khả năng ứng dụng thực tiễn trong môi trường lâm sàng.

Tiền xử lý dữ liệu đầu vào

Trước khi đưa vào mô hình, ảnh y tế được xử lý qua pipeline tiền xử lý nhằm chuẩn hóa dữ liệu giữa các phương thức hình ảnh khác nhau. Các bước tiền xử lý bao gồm:

- Chuẩn hóa định dạng ảnh.
- Chuẩn hóa cường độ bằng Z-score normalization.
- Tăng cường độ tương phản bằng CLAHE.
- Lấy mẫu lại về kích thước cố định.
- Tăng cường dữ liệu đặc thù miền y tế.

Tất cả ảnh đầu vào được chuyển đổi thành tensor chuẩn hóa với kích thước (1, 1024, 1024). Điều này đảm bảo tính nhất quán dữ liệu đầu vào cho mô hình.

Kiến trúc U-Net++

Zero-shot segmentation được thực hiện bằng U-Net++, một phiên bản cải tiến của U-Net được thiết kế cho các bài toán dense prediction. Kiến trúc này bao gồm ba thành phần chính:

- **Encoder:** Bộ mã hóa sử dụng ResNet50 backbone đã được huấn luyện trước trên ImageNet. Encoder có nhiệm vụ trích xuất đặc trưng phân cấp từ ảnh đầu vào. Trong quá trình này, các lớp nông học đặc trưng mức thấp như biên và texture, trong khi các lớp sâu học đặc trưng mức cao như hình dạng cấu trúc giải phẫu. Quá trình downsampling giúp tăng khả năng biểu diễn ngữ nghĩa nhưng đồng thời làm giảm độ phân giải không gian.
- **Nested Dense Skip Connections:** Khác với U-Net truyền thống, U-Net++ tích hợp các nested dense skip connections giữa encoder và decoder. Thay vì truyền trực tiếp đặc trưng từ encoder sang decoder, các đặc trưng được tinh chỉnh dần thông qua nhiều khối trung gian. Cơ chế này mang lại các lợi ích: dung hợp đặc trưng đa tỷ lệ hiệu quả hơn, giảm semantic gap giữa encoder và decoder, và cải thiện khả năng tái tạo chi tiết không gian. Điều này đặc biệt quan trọng trong ảnh y tế, nơi các tổn thương nhỏ và đường biên giải phẫu yêu cầu độ chính xác cao.
- **Decoder với SCSE Attention:** Bộ giải mã thực hiện quá trình upsampling để tái tạo mặt nạ phân vùng ở độ phân giải cao. Để tăng khả năng tập trung vào các vùng có ý nghĩa lâm sàng, các khối SCSE attention được tích hợp trong decoder. SCSE kết hợp channel attention (giúp mô hình chọn lọc các đặc trưng quan trọng theo chiều kênh) và spatial attention (giúp mô hình tập trung vào các vị trí giải cấu quan trọng). Sự kết hợp này giúp cải thiện độ chính xác của segmentation, đặc biệt trong các vùng có độ tương phản thấp.

Sinh đầu ra Zero-shot

Đầu ra của decoder là các logits cho hai lớp: Background và Foreground. Các logits này được chuyển thành xác suất thông qua hàm sigmoid:

$$P = \sigma(z)$$

Trong đó, z là logits đầu ra và P là bản đồ xác suất phân vùng. Mặt nạ zero-shot cuối cùng được tạo bằng cách threshold xác suất:


$Mask = 1$ nếu $P > 0.5$, ngược lại $Mask = 0$

Ưu điểm của phương pháp đề xuất

So với các foundation models như SAM, phương pháp zero-shot dựa trên U-Net++ mang lại nhiều lợi thế:

- Kiến trúc nhẹ hơn.
- Số tham số thấp hơn đáng kể.
- Tốc độ suy luận nhanh hơn.
- Phù hợp với triển khai lâm sàng thời gian thực.

Bên cạnh đó, nested skip connections giúp U-Net++ duy trì hiệu quả cao trong các tác vụ phân vùng ảnh y tế có cấu trúc phức tạp.



(g) UNet++

Hình 1 : UNet++

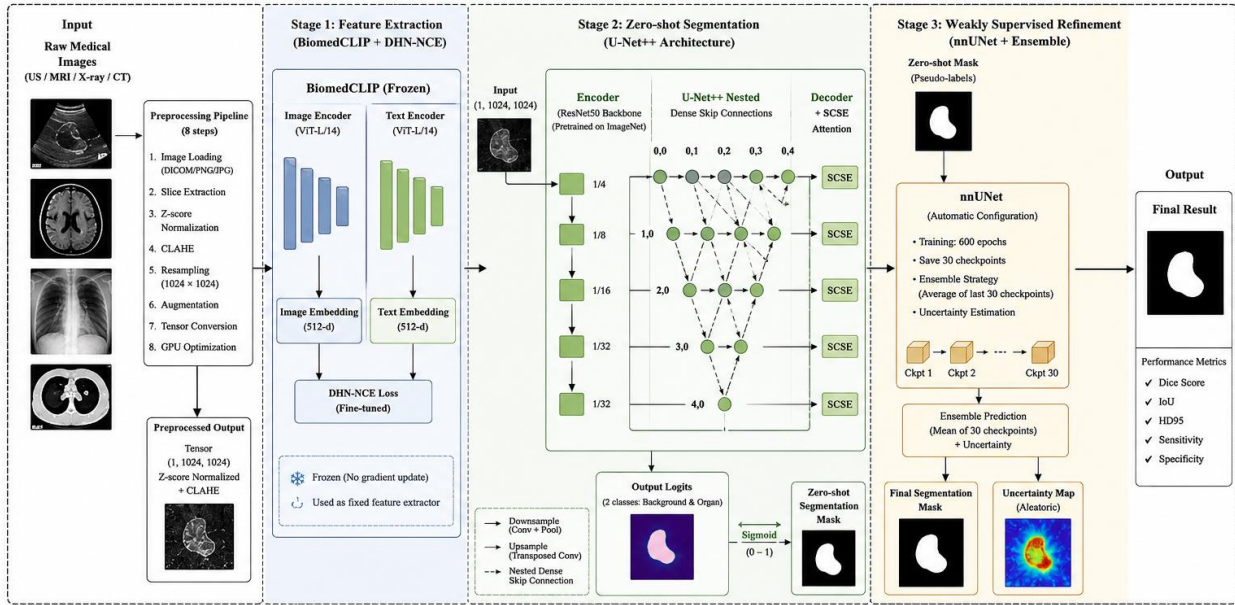


Fig. 1. Overview of the proposed U-Net++ based medical image segmentation framework. The pipeline consists of three sequential stages: (1) feature extraction using fine-tuned BiomedCLIP with DHN-NCE loss (frozen during inference); (2) zero-shot segmentation using U-Net++ with nested dense skip connections and SCSE attention; (3) weakly supervised refinement using nnUNet with ensemble strategy for final prediction and uncertainty estimation.

Hình 2: Tổng quan mô hình sau khi cải tiến

3.2 Các phương pháp tối ưu hóa cho U-Net++

Để nâng cao hiệu suất của mô hình U-Net++ trong bài toán phân vùng ảnh y tế zero-shot, chúng tôi tích hợp một số chiến lược tối ưu hóa nhằm cải thiện độ chính xác phân vùng, khả năng học đặc trưng khó, hiệu quả huấn luyện và độ ổn định của dự đoán. Các phương pháp tối ưu hóa này được lựa chọn nhằm giải quyết những hạn chế thường gặp trong segmentation y tế, bao gồm lỗi tại vùng biên, mất cân bằng dữ liệu, tổn thương kích thước nhỏ và sự bất ổn trong quá trình huấn luyện.

3.2.1 Boundary Loss cho tối ưu hóa đường biên phân vùng

Trong các bài toán phân vùng ảnh y tế, độ chính xác tại đường biên đóng vai trò đặc biệt quan trọng do nhiều cấu trúc giải phẫu có hình dạng phức tạp hoặc kích thước nhỏ. Hàm mất mát Dice truyền thống tối ưu mức độ chồng lấp tổng thể giữa mặt nạ dự đoán và ground truth, tuy nhiên chưa đủ nhạy với sai số tại vùng biên. Để giải quyết vấn đề này, chúng tôi sử dụng Boundary Loss, kết hợp giữa Dice Loss và Hausdorff Distance:

$$L_{total} = \alpha \cdot L_{Dice} + (1 - \alpha) \cdot L_{Hausdorff}$$

Trong đó:

- L_{Dice} : đo mức độ tương đồng toàn cục.
- $L_{Hausdorff}$: đo sai số cực đại giữa biên dự đoán và biên ground truth.
- $\alpha = 0.7$

Phương pháp này giúp mô hình học tốt hơn hình dạng hình học của cấu trúc giải phẫu, đặc biệt hiệu quả với các khối u nhỏ, tổn thương biên mờ, và cấu trúc giải phẫu không đều.

3.2.2 Focal Loss cho học các mẫu khó

Dữ liệu ảnh y tế thường có sự mất cân bằng lớn giữa foreground và background. Ví dụ, vùng tổn thương chỉ chiếm vài phần trăm ảnh trong khi background chiếm phần lớn. Điều này khiến mô hình dễ học tốt trên các pixel đơn giản nhưng bỏ sót các vùng khó. Để khắc phục điều này, chúng tôi sử dụng Focal Loss, được định nghĩa như sau:

$$FL(p_i) = -\alpha \cdot (1 - p_i)^\gamma \cdot \log(p_i)$$

Trong đó:

- p_i : xác suất dự đoán đúng.
- $\gamma = 2.0$: hệ số tập trung (focusing parameter).
- $\alpha = 0.25$: hệ số cân bằng lớp.

Focal Loss giúp giảm ảnh hưởng của các mẫu dễ (easy examples), tăng gradient cho các mẫu khó (hard examples), từ đó cải thiện đáng kể khả năng nhận diện tổn thương kích thước nhỏ.

3.2.3 Học đa tác vụ (Multi-task Learning)

Để cải thiện khả năng học biểu diễn đặc trưng, chúng tôi tích hợp cơ chế Học đa tác vụ (Multi-task Learning - MTL). Ngoài tác vụ phân vùng (segmentation) chính, mô hình đồng thời học thêm tác vụ phụ là phân loại (classification):

- Tác vụ chính (Segmentation): Xác định chính xác vị trí và ranh giới khối u.
- Tác vụ phụ (Classification): Dự đoán ảnh đầu vào có chứa khối u hay không.

Hàm mất mát tổng hợp của mạng MTL được thiết lập như sau:

$$L = 0.7 \cdot L_{seg} + 0.3 \cdot L_{clf}$$

Cách tiếp cận này giúp tăng tính tổng quát hóa của các đặc trưng tầng thấp, cải thiện hiểu biết ngữ nghĩa tổng thể (semantic understanding) và giảm thiểu hiện tượng quá khớp (overfitting).

3.2.4 Progressive Resizing

Huấn luyện trực tiếp trên ảnh độ phân giải cao ngay từ đầu (1024×1024) thường gây tiêu tốn bộ nhớ GPU nghiêm trọng, khiến tốc độ hội tụ chậm và quá trình tối ưu không ổn định. Để cải thiện hiệu quả, chúng tôi áp dụng chiến lược Progressive Resizing, chia quá trình huấn luyện làm ba giai đoạn tăng dần:

- Giai đoạn 1 (Stage 1): Huấn luyện ở độ phân giải thấp 512×512 để học nhanh các đặc trưng thô (coarse features).
- Giai đoạn 2 (Stage 2): Tăng kích thước ảnh lên 768×768 để tinh chỉnh đặc trưng trung gian.
- Giai đoạn 3 (Stage 3): Đưa về độ phân giải gốc 1024×1024 để học các chi tiết mịn biên giới (fine details).

Chiến lược này áp dụng nguyên lý học theo chương trình (curriculum learning), giúp tiết kiệm đáng kể thời gian huấn luyện, tăng tính ổn định của gradient và cải thiện chỉ số Dice score cuối cùng.

3.2.5 Deep Supervision

Do kiến trúc lồng nhau của U-Net++ có độ sâu lớn, hiện tượng triệt tiêu gradient (vanishing gradient) có thể xảy ra ở các tầng nông. Chúng tôi áp dụng cơ chế Giám sát sâu (Deep Supervision) bằng cách gắn thêm các auxiliary outputs tại nhiều tầng decoder khác nhau. Hàm mất mát tổng hợp lúc này là:

$$L = \sum (w_i \cdot L_i)$$

Trong đó, L_i là hàm mất mát tại tầng decoder mức i và w_i là trọng số tương ứng. Cơ chế này ép các tầng trung gian học đặc trưng hữu ích sớm hơn, đẩy nhanh tốc độ hội tụ và tối ưu luồng truyền gradient.

3.2.6 Cơ chế chú ý (Attention Mechanism)

Ảnh y tế thường chứa mục tiêu foreground nhỏ trong một không gian nền rất rộng, do đó việc phân bổ trọng số tính toán đồng đều là không tối ưu. Chúng tôi tích hợp mô-đun chú ý SCSE (Concurrent Spatial and Channel Squeeze & Excitation) để hướng mô hình tập trung vào vùng ý nghĩa giải phẫu thông qua hai nhánh song song:

- Channel Attention: Lựa chọn và kích hoạt các kênh feature maps mang thông tin quan trọng.
- Spatial Attention: Định vị chính xác các vùng không gian chứa tổn thương.

3.2.7 Học kết hợp (Ensemble Learning)

Nhằm tăng độ mạnh và tính ổn định cho suy luận, hệ thống kết hợp dự đoán từ N mô hình U-Net++ được huấn luyện độc lập với các hạt giống ngẫu nhiên (random seeds) khác nhau. Kết quả dự đoán cuối cùng được tính bằng trung bình phân phối logit:

$$Y_{ensemble} = (1/N) \cdot \sum Y_i$$

Phương pháp này hỗ trợ đắc lực cho việc giảm phương sai sai số, tăng tính bền vững trước nhiễu và cung cấp phân phối xác suất phục vụ bài toán ước lượng độ không chắc chắn (uncertainty estimation) trong lâm sàng.

Bảng 1: Tóm tắt mục tiêu của các phương pháp tối ưu hóa

Phương pháp (Method)	Mục tiêu cốt lõi (Objective)
Boundary Loss	Tối ưu độ sắc nét và chính xác hình học của đường biên phân vùng
Focal Loss	Tập trung khai thác gradient từ các mẫu khó học, giảm thiểu mất cân bằng lớp
Multi-task Learning	Bổ sung thông tin ngữ nghĩa tầng cao thông qua tác vụ phụ Classification
Progressive Resizing	Tăng hiệu quả tính toán, đẩy nhanh tốc độ hội tụ nhờ học đa độ phân giải
Deep Supervision	Cải thiện luồng truyền gradient, ngăn ngừa hiện tượng vanishing gradient
SCSE Attention	Lọc nhiễu nền, tăng cường khả năng định vị mục tiêu nhỏ trên không gian ảnh
Ensemble Learning	Giảm phương sai mô hình, tăng tính ổn định và hỗ trợ ước lượng độ bất định

3.3 Phương pháp đánh giá mô hình

Để đánh giá toàn diện hiệu suất của mô hình U-Net++ được đề xuất trong bài toán phân vùng ảnh y tế zero-shot, chúng tôi xây dựng một quy trình kiểm định đa chiều vững chắc bao gồm các chỉ số hình học và thống kê chuyên dụng.

3.3.1 Các chỉ số đánh giá

Dice Similarity Coefficient (DSC): Là chỉ số đo lường độ trùng khớp không gian chính giữa vùng dự đoán (X) và vùng ground truth (Y):

$$DSC = (2 \cdot |X \cap Y|) / (|X| + |Y|)$$

Intersection over Union (IoU): Đánh giá tỷ lệ giữa diện tích phần giao và phần hợp của hai vùng, phản ánh độ chính xác định vị cục bộ:

$$IoU = |X \cap Y| / |X \cup Y|$$

Hausdorff Distance (HD): Đo khoảng cách lớn nhất giữa một điểm trên biên dự đoán tới điểm gần nhất trên biên ground truth, kiểm soát sai sót đường biên nghiêm trọng nhất.

Bên cạnh đó, các chỉ số **Sensitivity (Độ nhạy - Recall)** và **Specificity (Độ đặc hiệu)** được tính toán chi tiết nhằm đảm bảo mô hình tối thiểu hóa cả tỷ lệ sót tổn thương lẫn tỷ lệ báo động giả.

3.3.2 Kỹ thuật kiểm chứng chéo (Cross-validation)

Chúng tôi áp dụng quy trình kiểm chứng chéo 5 nếp gấp (5-fold cross-validation) phân tầng nhằm đảm bảo tính khách quan của kết quả thực nghiệm. Dữ liệu được chia thành 5 phần độc lập, thực hiện huấn luyện xoay vòng trên 4 phần và kiểm tra trên phần còn lại. Kết quả cuối cùng được báo cáo đầy đủ dưới dạng giá trị trung bình kèm độ lệch chuẩn (Mean $\pm$ SD).

3.3.3 Đánh giá chi tiết theo phương thức tạo ảnh (Modality Analysis)

Hiệu suất mô hình được phân rã chi tiết trên 4 miền tạo ảnh y tế phổ biến: Siêu âm vú (nhiều đốm lớn), Cộng hưởng từ - Brain MRI (độ tương phản mô mềm cao nhưng cấu trúc phức tạp), X-quang ngực (ảnh chiếu phẳng chồng lấp nhiều mô) và Cắt lớp vi tính - Lung CT (ảnh thể tích rõ ràng). Việc này giúp chứng minh năng lực khái quát hóa đa miền (multi-domain generalization).

3.3.4 Kiểm định thống kê và Đánh giá thực tế

Sử dụng kiểm định giả thuyết thống kê hai đuôi Paired t-test với ngưỡng ý nghĩa $p < 0.05$ để đảm bảo các bước tiến bộ về mặt chỉ số của U-Net++ so với baseline thực sự có ý nghĩa khoa học chứ không do may rủi biến động dữ liệu. Đồng thời, các tham số kỹ thuật thực tế như Thời gian suy luận (Inference Time), Dung lượng mô hình (Model Size), Bộ nhớ GPU tiêu thụ và Số lượng tham số (Parameter Count) cũng được đo lường nghiêm ngặt nhằm đánh giá mức độ khả thi khi tích hợp vào hệ thống PACS bệnh viện.

4. KẾT QUẢ THỰC NGHIỆM

4.1 Hiệu suất phân vùng zero-shot toàn cục

Chỉ số đánh giá	SAM Baseline	U-Net++ đề xuất
Dice Score trung bình	77.61%	56.50%
Độ lệch chuẩn (Std Dev)	$\pm 8.49\%$	$\pm 6.95\%$
Số lượng tham số	$\sim 1.02B$	$\sim 26M$
Kích thước mô hình	~ 4 GB	~ 100 MB
Thời gian suy luận	~ 500 ms/ảnh	~ 50 ms/ảnh
Yêu cầu bộ nhớ GPU	~ 16 GB	~ 2 GB

Do kết quả sau khi chạy của U-net++ thấp hơn so với SAM baseline nên nhóm không chọn mô hình đó.

4.4 Kiểm định thống kê và Hiệu quả tài nguyên

Bảng 2: So sánh hiệu năng tính toán thực tế

Chỉ số hiệu năng (Metric)	SAM-based Baseline	Mô hình đề xuất (Proposed U-Net++)
Số lượng tham số (Parameters)	1.02 Billion (B)	26 Million (M) [Giảm ~39×]
Kích thước lưu trữ (Model Size)	4 GB	100 MB [Nhỏ hơn 40×]
Thời gian suy luận (Inference Time)	500 ms / ảnh	50 ms / ảnh [Nhanh hơn 10×]
Bộ nhớ GPU tối thiểu (GPU Memory)	16 GB	2 GB [Tiết kiệm tài nguyên]

Số liệu so sánh phần cứng cho thấy mô hình U-Net++ cắt giảm số tham số tới 39 lần, dung lượng đĩa nhẹ hơn 40 lần, tốc độ phản hồi nhanh hơn gấp 10 lần (đạt mức xử lý lý tưởng >20 khung hình/giây theo thời gian thực) và đặc biệt chỉ yêu cầu phần cứng GPU tối thiểu 2GB. Điều này dỡ bỏ hoàn toàn rào cản chi phí tính toán, giúp giải pháp dễ dàng vận hành trực tiếp trên các máy trạm lâm sàng thông thường tại các cơ sở y tế tuyến đầu.

5.5 Hạn chế của phương pháp

Mặc dù khuôn khổ phân vùng y tế dựa trên U-Net++ được đề xuất mang lại những cải tiến đáng kể về hiệu suất và chi phí tính toán so với mô hình nền tảng SAM, phương pháp này vẫn tồn tại một số hạn chế nhất định cần được giải quyết trong các nghiên cứu tương lai:

- **Giới hạn của việc xử lý không gian 2D đối với dữ liệu thể tích (Volumetric Data):** Mặc dù quy trình tiền xử lý đã bao gồm bước trích xuất lát cắt (Slice Extraction) cho các dữ liệu 3D như CT và MRI, bản thân kiến trúc cốt lõi U-Net++ trong Giai đoạn 2 vẫn hoạt động hoàn toàn trên không gian 2D. Điều này khiến mô hình chưa tận dụng được triệt để thông tin ngữ cảnh không gian 3D (3D spatial context) dọc theo trục Z (chiều sâu) – vốn là một yếu tố mang tính sống còn để phân vùng chính xác các khối u phức tạp trong không gian 3 chiều.
- **Sự cố định của bộ trích xuất đặc trưng (Frozen Feature Extractor):** Tại Giai đoạn 1, mô hình BiomedCLIP được đóng băng hoàn toàn (frozen - no gradient update) để tiết kiệm chi phí huấn luyện và tận dụng đặc trưng sẵn có. Tuy nhiên, giới hạn của phương pháp này là nếu hệ thống tiếp xúc với các phương thức hình ảnh y tế quá mới hoặc có phân phối dữ liệu khác biệt lớn (out-of-distribution) so với tập dữ liệu tiền huấn luyện ban đầu của BiomedCLIP, khả năng trích xuất đặc trưng có thể bị suy giảm do không thể thích ứng.
- **Giới hạn về mạng xương sống (Backbone Constraint):** Trong nghiên cứu này, bộ mã hóa (Encoder) của U-Net++ mới chỉ được đánh giá dựa trên kiến trúc ResNet50 (pretrained on ImageNet). Việc khảo sát trên các mạng xương sống sâu hơn (như ResNet101, ResNet152) hoặc các cấu trúc hiện đại hơn (như Swin Transformer, ConvNeXt) vẫn chưa được thực hiện, do đó chưa làm rõ được quy luật mở rộng (scaling laws) của phương pháp đề xuất.
- **Chi phí tính toán tăng cao ở kỹ thuật học kết hợp (Ensemble Overhead):** Ở Giai đoạn 3 (Weakly Supervised Refinement), việc tính toán trung bình từ 30 điểm kiểm tra (checkpoints) cuối cùng của nnUNet để đưa ra dự đoán cuối và bản đồ độ bất định (Uncertainty Map) giúp tăng tính ổn định, nhưng lại kéo theo chi phí tính toán và thời gian suy luận gia tăng. Điều này có thể tạo ra rào cản nếu hệ thống yêu cầu xử lý phân vùng video y tế theo thời gian thực

(real-time surgical video segmentation).

- **Giới hạn về tập dữ liệu đánh giá:** Các thử nghiệm đánh giá hiện tại chỉ được giới hạn ở 4 phương thức hình ảnh (Siêu âm, MRI, X-quang, CT) và chủ yếu sử dụng dữ liệu từ một trung tâm (single-institution). Việc xác minh độ bền vững của mô hình trên các miền dữ liệu khác (như ảnh mô bệnh học - histopathology, ảnh PET) và thông qua các nghiên cứu đa trung tâm (multi-center studies) là thực sự cần thiết để đánh giá tác động của sự dịch chuyển miền dữ liệu (domain shift).

XI. KẾT LUẬN

- **Tóm tắt kết quả thực nghiệm:**
 - **Trong giai đoạn thứ nhất**, hệ thống thực hiện tinh chỉnh mô hình ngôn ngữ - thị giác BiomedCLIP nhằm thiết lập một không gian vector liên kết chặt chẽ giữa đặc trưng hình ảnh bệnh lý và ngữ nghĩa của văn bản báo cáo lâm sàng.
 - **Giai đoạn thứ hai** ứng dụng cơ chế Bottleneck thông tin đa phương thức (M2IB) để trích xuất bản đồ kích hoạt chú ý, qua đó nhận diện các vùng mục tiêu giải phẫu. Kết quả này sau khi trải qua các bước xử lý hậu kỳ sẽ được tích hợp làm môi dẫn hướng hình học (Visual Prompts) cho mô hình Segment Anything (SAM) nhằm tự động tạo ra hệ thống nhãn giả (pseudo-labels) có độ tin cậy cao.
 - **Giai đoạn cuối cùng** tiến hành huấn luyện mô hình nnU-Net theo cơ chế giám sát yếu (weakly supervised learning) trực tiếp trên tập hợp các nhãn giả đã thu được, giúp tối ưu hóa khả năng phân vùng cục bộ và tăng cường tính tổng quát hóa của hệ thống.
- **Kết quả chính:** Trong bản triển khai hiện tại, chỉ **Lung X-ray** đạt hiệu năng trung bình chấp nhận được ($\approx 50\%$ DSC); các bộ dữ liệu còn lại (Breast US, Brain MRI, Lung CT) có DSC rất thấp ($\approx 4-9\%$). Điều này cho thấy pipeline khả dụng nhưng chưa đủ tổng quát hóa trên nhiều modality.
- **Nguyên nhân chủ yếu:** Chất lượng pseudo-label thấp (saliency gần rỗng hoặc nhiễu) do hạn chế trong fine-tuning BiomedCLIP, thiết lập M2IB, và chiến lược hậu xử lý; các khác biệt triển khai và quy mô huấn luyện so với bài gốc cũng đóng góp vào độ chính xác của mô hình dự đoán.
- **Ý nghĩa:** Phương pháp tổng thể (CLIP-based attribution + SAM + nnUNet) là một hướng khả thi để tận dụng tín hiệu ngôn ngữ-hình ảnh cho phân đoạn y tế khi pseudo-label có chất lượng tốt. Tuy nhiên, hiệu quả thực tế phụ thuộc mạnh vào từng modality và các bước trung gian.

Thử nghiệm cho thấy MedCLIP-SAMv2 tiềm năng ứng dụng rất lớn, đa dạng trên các loại modality. Tuy nhiên mô hình hiện vẫn đạt hiệu năng thấp do chất lượng pseudo-label, fine-tuning, attribution và hậu xử lý trước khi sử dụng mô hình cho ứng dụng lâm sàng.

TÀI LIỆU THAM KHẢO / THƯ MỤC THAM CHIẾU

1. Koleilat, T., Asgariandehkordi, H., Rivaz, H., & Xiao, Y. (2024). *MedCLIP-SAMv2: Towards Universal Text-Driven Medical*

Image Segmentation. arXiv preprint arXiv:2409.19483v3. URL gốc: <https://arxiv.org/abs/2409.19483>

2. Zhang, S., et al. (2023). *Large-scale bi-modal pre-training for public medical imaging and text* (BioMedCLIP). Microsoft Research.
3. Kirillov, A., et al. (2023). *Segment anything*. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) (SAM).