


I. GIỚI THIỆU

Phân đoạn ảnh y tế (Medical Image Segmentation) đóng vai trò cốt lõi trong quy trình hỗ trợ chẩn đoán lâm sàng, lập kế hoạch điều trị và theo dõi tiến triển bệnh lý. Mặc dù các mô hình học sâu truyền thống dựa trên kiến trúc Fully Convolutional Networks (FCN) hoặc U-Net đã đạt được những thành tựu vượt bậc, chúng vẫn bộc lộ những hạn chế nghiêm trọng về tính linh hoạt: mô hình thường bị bó hẹp trong một loại cơ quan hoặc một phương thức hình ảnh y tế cố định và đòi hỏi lượng dữ liệu gán nhãn pixel-level vô cùng lớn.

Nhằm giải quyết triệt để rào cản này, framework **MedCLIP-SAMv2** được đề xuất như một giải pháp tiên phong, tích hợp sức mạnh hiểu ngữ nghĩa đa phương thức của mô hình nền tảng y sinh **BioMedCLIP** và khả năng phân đoạn hình học mạnh mẽ của **Segment Anything Model (SAM)**. Sự kết hợp mang tính đột phá này mở ra khả năng phân đoạn ảnh y tế dựa trên gợi ý văn bản (**text-driven segmentation**), cho phép người dùng điều khiển mô hình thông qua các câu lệnh tự nhiên mô tả thực thể bệnh học.

Mô hình thể hiện ưu thế vượt trội ở cả hai kịch bản phân đoạn không cần huấn luyện lại (**zero-shot segmentation**) và phân đoạn giám sát yếu (**weakly supervised segmentation**) trên đa dạng các phương thức chẩn đoán hình ảnh (**modalities**) như Siêu âm (Ultrasound), Cộng hưởng từ (MRI), Cắt lớp vi tính (CT), và X-quang (X-ray). Báo cáo học thuật này tập trung phân tích sâu kiến trúc hệ thống, các cải tiến cốt lõi từ bài báo gốc, đồng thời ghi nhận kết quả từ kho lưu trữ thực nghiệm cá nhân được triển khai trên môi trường phần cứng cục bộ.

Báo cáo này tập trung chủ yếu vào việc phân tích kiến trúc và tái hiện pipeline thực nghiệm từ repository replication cá nhân, thay vì đề xuất một kiến trúc mô hình mới.



[HÌNH MINH HỌA KIẾN TRÚC TỔNG QUAN MEDCLIP-SAMv2]

Hình 1: Mô hình hóa ý tưởng text-driven medical image segmentation kết hợp giữa Vision-Language Models (BioMedCLIP) và Foundation Models cho phân đoạn ảnh (SAM).

II. MỤC TIÊU NGHIÊN CỨU

Báo cáo này tập trung vào việc phân tích và tái hiện pipeline MedCLIP-SAMv2 từ bài báo [1], không đề xuất kiến trúc mới. Các mục tiêu chính bao gồm:

- Nghiên cứu sâu kiến trúc hệ thống:** Phân tích cơ chế liên kết đa phương thức giữa mô hình mã hóa ngôn ngữ-hình ảnh y tế (BioMedCLIP) và mô hình phân đoạn hình học (SAM), đặc biệt là vai trò trung gian của

khối nghẽn thông tin đa phương thức (Multi-modal Information Bottleneck - M2IB).

- **Tái hiện thành công thực nghiệm:** Triển khai mã nguồn từ bài báo gốc, cấu hình môi trường phần cứng cục bộ và tối ưu hóa quy trình chạy pipeline zero-shot từ kho lưu trữ Blackdarked/MedCLIP-SAMv2.
- **Đánh giá hiệu quả định lượng:** Đo lường năng lực phân đoạn dựa trên các chỉ số tiêu chuẩn của ngành y tế (Dice Coefficient, Intersection over Union - IoU) trên tập dữ liệu kiểm thử.
- **So sánh hiệu năng:** Đặt hiệu quả phân đoạn của MedCLIP-SAMv2 trong bức tranh so sánh đối chiếu với các phương pháp học sâu truyền thống giám sát hoàn toàn (Full-supervised U-Net) và mô hình SAM nguyên bản không có định hướng ngữ nghĩa y khoa.

[SƠ ĐỒ MA TRẬN ĐỐI CHIẾU PHƯƠNG PHÁP]

Hình 2: Sơ đồ tư duy về các mục tiêu nghiên cứu và trục tọa độ so sánh giữa tính linh hoạt (Zero-shot) và độ chính xác phân đoạn.

III. CƠ SỞ LÝ THUYẾT

A. Bài toán Phân đoạn ảnh Y tế (Medical Image Segmentation)

BiomedCLIP là mô hình CLIP được huấn luyện trên cặp ảnh–văn bản y sinh học đa dạng, cho phép trích xuất embedding hàm ý cho cả ảnh y tế và ngữ cảnh bệnh lý [1]. Để cải thiện khả năng phân biệt giữa các cặp ảnh–văn bản liên quan và không liên quan, tác giả [1] đề xuất hàm mất mát Decoupled Hard Negative Noise Contrastive Estimation (DHN-NCE). DHN-NCE kết hợp phương pháp chọn mẫu âm tính khó (hard negative sampling) và tách rời thành phần dương trong hàm InfoNCE truyền thống, giúp tăng cường trọng số phạt lên các mẫu âm gần với ảnh gốc, từ đó nâng cao hiệu quả huấn luyện ngay cả với batch nhỏ. Quá trình fine-tuning BiomedCLIP với DHN-NCE tập trung vào việc tối ưu hóa hàm mất mát kết hợp giữa các cặp ảnh–văn bản liên quan (positive) và không liên quan (negative) như mô tả trong [1].

B. Các Chỉ số Đánh giá (Evaluation Metrics)

Để đánh giá mức độ hội tụ và độ chính xác của vùng phân đoạn dự đoán (X) so với vùng gán nhãn chuẩn ground-truth (Y), hai đại lượng toán học phổ biến nhất được sử dụng là chỉ số Dice (Dice Coefficient/Score) và IoU (Intersection over Union):

1. Chỉ số Dice Score: $Dice = \frac{2|X \cap Y|}{|X| + |Y|}$

Chỉ số Dice đo lường mức độ tương đồng toàn cục, nhấn mạnh vào phần giao nhau của hai vùng không gian.

2. Chỉ số IoU (Jaccard Index): $IoU = \frac{|X \cap Y|}{|X \cup Y|}$

Mối quan hệ toán học giữa hai chỉ số này được biểu diễn qua phương trình: $IoU = \frac{Dice^2}{2 - Dice}$. Cả hai metric đều dao động trong khoảng $[0, 1]$, giá trị tiến gần về 1 biểu thị độ chính xác hoàn hảo.

C. Mô hình nền tảng Segment Anything Model (SAM)

Segment Anything Model (SAM) là một mô hình nền tảng (Foundation Model) mang tính cách mạng trong lĩnh vực thị giác máy tính do Meta AI phát triển. SAM được huấn luyện trên tập dữ liệu khổng lồ SA-1B (hơn 11 triệu hình ảnh và 1 tỷ mặt nạ), mang lại năng lực phân đoạn vạn năng vật thể bất kỳ ở chế độ không cần huấn luyện lại (Zero-shot Transfer). Cấu trúc của SAM được chia thành 3 khối xử lý chính:

- Image Encoder (Bộ mã hóa hình ảnh):** Sử dụng kiến trúc mạng mạnh mẽ Vision Transformer (ViT-B, ViT-L hoặc ViT-H) kết hợp với kỹ thuật tiền huấn luyện Masked Autoencoders (MAE). Bộ phận này chịu trách nhiệm trích xuất toàn bộ đặc trưng không gian và ngữ nghĩa độ phân giải cao từ ảnh y tế đầu vào dưới dạng một ma trận embedding cố định.
- Prompt Encoder (Bộ mã hóa gợi ý):** SAM hỗ trợ tương tác linh hoạt đa dạng với các định dạng prompt dẫn đường bao gồm: *point prompts* (tọa độ các điểm nằm trong hoặc ngoài vật thể), *bounding box* (khung hộp giới hạn vùng không gian chứa vật thể), và cả *segmentation prompts / masks* (mặt nạ thô từ bước xử lý trước). Khối này thực hiện nhúng vị trí (positional encodings) cho các cấu trúc hình học trên.
- Mask Decoder (Bộ giải mã mặt nạ):** Một mạng decoder gọn nhẹ áp dụng cơ chế tự chú ý hai chiều (Two-way Cross-Attention Transformer). Nó liên kết đồng thời ma trận đặc trưng ảnh từ Image Encoder và chuỗi

vector nhúng gợi ý từ Prompt Encoder để thực hiện suy luận ra biên giới ranh giới thực thể, xuất bản mặt nạ nhị phân độ chính xác cao kèm điểm số tin cậy IoU.

D. Cơ chế chuyển đổi Visual Attention Map thành Prompt dẫn đường tự động cho SAM

Trong các ứng dụng SAM nguyên bản, hệ thống bắt buộc phải nhận điểm tương tác hoặc hộp bao do người dùng vẽ tay. Trong MedCLIP-SAMv2, luồng vận hành này đã được tự động hóa hoàn toàn bằng cách sử dụng **Visual Attention Map (Bản đồ chú ý trực quan)** sinh ra từ M2IB làm prompt động hướng dẫn cho SAM:


1. **Bản đồ chú ý y học:** Khối M2IB tính toán mật độ thông tin tương hỗ, xuất ra một ma trận bản đồ nhiệt chỉ thị chính xác vùng không gian ẩn chứa đối tượng bệnh lý tương đồng với chuỗi văn bản chỉ dẫn (Text Prompt từ BioMedCLIP).
2. **Trích xuất Point Prompts tự động:** Thuật toán quét qua bản đồ chú ý, dò tìm các tọa độ có giá trị kích hoạt cực đại (Local Maxima). Các điểm có cường độ cao nhất vượt qua ngưỡng \$ au\$ được coi là Điểm dương (Positive Points) nằm chắc chắn trong lỗi tổn thương để nạp vào Prompt Encoder.
3. **Trích xuất Bounding Box tự động:** Bản đồ chú ý dạng xám liên tục được áp dụng thuật toán phân ngưỡng nhị phân Otsu để lọc ra các cụm pixel hoạt hóa thô. Hệ thống sau đó áp dụng phép tìm đường biên (Contour Detection) bao quanh cụm đa giác này để tự động tính toán ra tọa độ của hộp bao tối thiểu \$ [X_{\min}, Y_{\min}, X_{\max}, Y_{\max}]\$, loại bỏ hoàn toàn việc vẽ tay của bác sĩ lâm sàng mà vẫn đảm bảo tính khách quan y khoa.

[SƠ ĐỒ TRỰC QUAN TOÁN HỌC DICE VÀ IOU - KIẾN TRÚC THÀNH PHẦN SAM]

Hình 3: Trực quan hóa hình học không gian vùng giao và cơ chế luồng Prompts tự động (Point/Box) kết nối từ Attention Map vào Prompt Encoder của SAM.

IV. KIẾN TRÚC MEDCLIP-SAMV2

Pipeline xử lý của framework MedCLIP-SAMv2 là một quy trình khép kín, chuyển đổi thông tin từ ảnh y tế thô và văn bản chỉ dẫn thành một mặt nạ phân đoạn chính xác cao. Quy trình bao gồm 6 thành phần cốt lõi được kết nối tuần tự:



[SƠ ĐỒ KHỐI CHI TIẾT PIPELINE MEDCLIP-SAMv2]

Hình 4: Sơ đồ kiến trúc luồng dữ liệu (Dataflow) từ dữ liệu đầu vào, qua khối embedding đa phương thức, trích xuất Saliency Map qua M2IB và sinh Mask bằng SAM.

A. Các thành phần chính trong Pipeline

- Medical Image (Ảnh y tế đầu vào):** Ảnh 2D từ các phương thức chụp chiếu, được biểu diễn dưới dạng ma trận điểm ảnh [I](#).
- Text Prompt (Gợi ý văn bản):** Chuỗi ký tự tự nhiên mô tả mục tiêu cần phân đoạn (ví dụ: "breast tumor", "lung nodule"). Văn bản này được xử lý thông qua bộ mã hóa của BioMedCLIP để sinh ra text embedding.
- BioMedCLIP (Vision-Language Base Model):** Khác với CLIP thông thường vốn được huấn luyện trên ảnh tự nhiên, BioMedCLIP được tiền huấn luyện trên tập dữ liệu khổng lồ gồm 15 triệu cặp ảnh-văn bản y sinh từ cơ sở dữ liệu PubMed. Nhờ đó, mô hình sở hữu khả năng liên kết ngữ nghĩa y khoa cực kỳ sâu sắc, chuyển đổi ảnh [I](#) thành visual embedding và câu lệnh văn bản thành text embedding tương ứng trong cùng một không gian ẩn (shared latent space).
- M2IB (Multi-modal Information Bottleneck):** Đây là thành phần cốt lõi tạo nên tính đột phá. M2IB tối đa hóa lượng thông tin tương hỗ (*Mutual Information*) giữa visual embedding và text embedding, đồng thời loại bỏ các thành phần nhiễu không liên quan trong ảnh gốc. Kết quả của M2IB là một bản đồ nhiệt biểu diễn sự chú ý (*Attention/Saliency Map*), chỉ rõ tọa độ không gian ẩn chứa thực thể được mô tả trong văn bản gợi ý.
- SAM (Segment Anything Model):** Mô hình nền tảng phân đoạn ảnh của Meta. SAM nhận đầu vào là ảnh gốc cùng các điểm gợi ý hoặc hộp bao được sinh tự động thông qua cơ chế phân ngưỡng bản đồ chú ý từ khối M2IB.
- Segmentation Mask (Mặt nạ phân đoạn):** SAM thực hiện giải mã (decode) các cấu trúc hình học và biên giới pixel để trả về kết quả phân đoạn nhị phân cuối cùng, phân tách rạch ròi vùng tổn thương và mô lành.

B. Hàm mất mát cải tiến DHN-NCE

Một đóng góp lý thuyết quan trọng của phiên bản v2 là việc áp dụng hàm mất mát **Decoupled Hard Negative Noise Contrastive Estimation (DHN-NCE)** trong pha tinh chỉnh BioMedCLIP. Hàm DHN-NCE giải quyết hiệu quả hiện tượng tiêu cực liên kết (negative-coupling effect) bằng cách loại bỏ mẫu dương khỏi mẫu số của biểu thức tương phản, giúp tối ưu hóa bộ nhớ và tăng cường khả năng phân biệt giữa các tổn thương y khoa có hình thái tương đồng nhưng bản chất bệnh lý khác nhau.

V. MÔI TRƯỜNG THỰC NGHIỆM

Các thí nghiệm tái hiện (replication) được triển khai trên máy tính sử dụng GPU NVIDIA GeForce RTX 4060 Ti 16GB VRAM và môi trường Windows 11. Toàn bộ pipeline được xây dựng dựa trên repository MedCLIP-SAMv2 phiên bản tái hiện cho Windows, bao gồm ba giai đoạn: fine-tuning BioMedCLIP, zero-shot segmentation bằng M2IB + SAM và weakly supervised segmentation với nnUNet v2.

Dữ liệu thực nghiệm bao gồm bốn tập dữ liệu public tương ứng với các modality trong bài báo: Breast Ultrasound, Brain MRI, Chest X-ray và Lung CT.

Thành phần	Thông số chi tiết / Phiên bản	Vai trò trong Hệ thống thực nghiệm
GPU	NVIDIA GeForce RTX 4060 Ti (16GB VRAM)	Tăng tốc tính toán tensor, lưu trữ trọng số mã hóa của ViT-H SAM và BioMedCLIP.
RAM	16GB DDR4 @3200MHz	Xử lý luồng dữ liệu, nạp dataset và tiền xử lý ảnh kích thước lớn.
Hệ điều hành	Windows 11	Môi trường chính để chạy pipeline replication MedCLIP-SAMv2.
Python	Python 3.11	Ngôn ngữ lập trình nền tảng của toàn bộ hệ thống.
PyTorch	PyTorch 2.1.2 + CUDA 12.1	Framework tính toán học sâu chính, quản lý bộ nhớ GPU.
open_clip_torch	v2.24.0	Triển khai BioMedCLIP và DHN-NCE trong Stage 1.
SAM Backbone	Segment Anything Model ViT-H	Sinh mask phân đoạn từ các bounding box hoặc point prompts được tạo tự động.
nnUNet	nnUNet v2	Huấn luyện mô hình weakly supervised segmentation bằng pseudo-labels.
scikit-image / Pillow	scikit-image, Pillow	Tiền xử lý ảnh, Otsu thresholding, xử lý mask và connected components.
NumPy / SciPy	NumPy, SciPy	Thực hiện tính toán ma trận, chuẩn hóa dữ liệu, thực hiện tính toán ma trận, nội suy và xử lý dữ liệu số.
pandas	pandas	Tổng hợp bảng kết quả và lưu kết quả thực nghiệm.
tqdm	tqdm	Hiển thị tiến trình huấn luyện và suy luận pipeline.
Matplotlib	Matplotlib	Trực quan hóa attention map, segmentation mask và kết quả thực nghiệm.

Thiết lập huấn luyện

Do giới hạn phần cứng GPU đơn (RTX 4060 Ti 16GB VRAM), một số tham số huấn luyện đã được giảm so với cấu hình trong bài báo gốc.

Hạng mục	Bài báo gốc	Tái hiện nhóm
nnUNet training cycles	3 chu kỳ	1 chu kỳ
Epoch mỗi cycle	200	200

Iterations / epoch	250	50
DataLoader workers	–	num_workers = 0

VI. TẬP DỮ LIỆU (DATASET)

Thực nghiệm đánh giá khả năng tổng quát hóa toàn diện của MedCLIP-SAMv2 thông qua việc phân đoạn trên 4 tập dữ liệu y tế đại diện cho 4 modality riêng biệt:

- Breast Ultrasound (BUSI / UDIAT): Ảnh siêu âm tuyến vú (khối u lành/ác tính). Thách thức lớn do nhiễu đốm dày đặc và độ tương phản ranh giới cực kém.
- Brain MRI (Br35H): Ảnh cộng hưởng từ não bộ (phân đoạn u não). Đòi hỏi mô hình nhận biết được sự thay đổi cường độ xám tinh tế và cấu hình mô dị biệt.
- Lung CT (LUNA16): Ảnh cắt lớp vi tính lồng ngực (phân đoạn tổn thương phổi/nốt đặc). Thách thức bởi lượng thông tin cấu trúc lớn và biên độ xám rộng.
- Chest X-ray (Montgomery + Shenzhen): Ảnh X-quang ngực phẳng 2D (phân đoạn nhu mô phổi). Đánh giá khả năng bóc tách vùng cấu trúc giải phẫu lớn dựa trên định hướng ngữ nghĩa văn bản.

A. Quy trình Tiền xử lý Dữ liệu (Data Preprocessing)

Mọi ảnh đầu vào từ các dataset trên đều phải trải qua chuỗi biến đổi nghiêm ngặt nhằm tương thích với kiến trúc mạng:

1. **Không gian hóa kích thước (Resizing):** Ở giai đoạn fine-tuning BiomedCLIP, ảnh được đưa về kích thước 224×224 theo preprocessing của OpenCLIP.
Ở giai đoạn huấn luyện nnUNet, ảnh và mask được resize đồng bộ về 256×256 để phù hợp với cấu hình mô hình.

Với SAM, ảnh và saliency map được xử lý theo cơ chế tiền xử lý riêng của mô hình.

2. **Chuẩn hóa cường độ (Normalization):**

Ảnh được chuẩn hóa về thang giá trị phù hợp với backbone sử dụng.

Với các mô hình kiểu CLIP/BiomedCLIP, có thể biểu diễn bằng công thức:

$$I_{norm} = \frac{I - \mu}{\sigma}$$

Trong đó, μ và σ là giá trị trung bình và độ lệch chuẩn của tập tiền huấn luyện.

3. **Xử lý mặt nạ và tạo pseudo-label:** Mask được chuyển về dạng nhị phân để phục vụ huấn luyện và đánh giá. Ở giai đoạn zero-shot, saliency map được nội suy lên kích thước ảnh gốc, sau đó áp dụng KMeans/Otsu và lọc các thành phần nhỏ để tạo pseudo-label. Khi resize mask, sử dụng nội suy gần nhất để giữ nguyên biên vùng tổn thương.

[HÌNH MINH HỌA CÁC MODALITY TRƯỚC VÀ SAU PREPROCESSING]

Hình 5: Trực quan hóa các mẫu dữ liệu từ bốn nguồn tập dữ liệu (Siêu âm vú, MRI não, CT phổi, X-ray ngực) sau khi qua bước chuẩn hóa kích thước và cường độ.

VII. QUY TRÌNH THỰC NGHIỆM

Quy trình thực nghiệm được triển khai tuần tự thông qua kịch bản tự động hóa từ tệp tin `zeroshot.sh` trong mã nguồn. Các giai đoạn vận hành của luồng thực thi bao gồm:

Quy trình thực nghiệm được triển khai tuần tự thông qua script điều phối chính của hệ thống là [run_all.py](#) (hoặc [full_run.bat](#) trên Windows).

Toàn bộ pipeline được thực hiện tuần tự qua ba giai đoạn chính: fine-tuning BiomedCLIP, sinh saliency/zero-shot segmentation bằng M2IB kết hợp SAM, và huấn luyện nnUNet trên các pseudo-label thu được từ giai đoạn trước. Kết quả trung gian và kết quả cuối cùng được lưu trong thư mục làm việc của hệ thống để phục vụ đánh giá và tái sử dụng ở các lần chạy sau

Bên dưới là chi tiết 4 giai đoạn xử lý chính diễn ra bên trong hệ thống:

- **Bước 1: Preprocessing (Tiền xử lý)**

Hệ thống đọc dữ liệu ảnh từ các thư mục đã được chia sẵn bởi tác giả cho từng bộ dữ liệu. Ở giai đoạn BiomedCLIP, ảnh đầu vào được chuyển về định dạng RGB và đưa qua bộ tiền xử lý chuẩn của OpenCLIP/BiomedCLIP, tương ứng với kích thước làm việc 224×224 . Ở giai đoạn chuẩn bị dữ liệu cho nnUNet, ảnh và mặt nạ được resize đồng bộ về kích thước cố định 256×256 theo cấu hình huấn luyện của mô hình. Mặt nạ ground truth được xử lý theo hướng nhị phân hóa để phù hợp với bài toán phân đoạn nhị phân.

- **Bước 2: Embedding Generation (Sinh vector nhúng):** Sau khi tiền xử lý, ảnh được đưa qua bộ mã hóa hình ảnh để thu được vector nhúng ảnh, trong khi mô tả văn bản tương ứng được token hóa và đưa qua bộ mã hóa văn bản để thu được vector nhúng ngôn ngữ. Hai biểu diễn này tạo thành cặp đặc trưng ảnh - văn bản, là đầu vào cho bước sinh saliency ở giai đoạn tiếp theo.

- **Bước 3: Attention Map Generation (Tạo bản đồ chú ý):** Khối sinh saliency tối ưu một mặt nạ theo từng vùng nhỏ của ảnh nhằm tăng mức tương đồng giữa đặc trưng ảnh và văn bản, đồng thời giảm ảnh hưởng của các vùng không liên quan. Kết quả thu được là một bản đồ saliency liên tục thể hiện mức độ quan trọng của từng vùng trong ảnh đối với mô tả văn bản. Bản đồ này sau đó được nội suy về kích thước ảnh gốc và xử lý hậu kỳ bằng phương pháp phân cụm để tách vùng nền và vùng quan tâm, đồng thời loại bỏ các thành phần nhỏ rời rạc nhằm tạo ra một mask thô.

- **Bước 4: Segmentation Inference (Suy luận phân đoạn):** Mask thô từ saliency map được dùng làm đầu vào gợi ý cho mô hình phân đoạn. Tùy theo cấu hình của từng bộ dữ liệu, mô hình có thể nhận đầu vào dưới dạng bounding box hoặc điểm gợi ý. Mô hình sau đó kết hợp ảnh gốc với prompt để tạo ra mặt nạ phân đoạn nhị phân cuối cùng. Các mặt nạ trung gian và mặt nạ cuối được lưu lại để phục vụ đánh giá. Ở bước đánh giá, hệ thống sử dụng các chỉ số Dice và NSD để đo chất lượng phân đoạn.

VIII. KẾT QUẢ THỰC NGHIỆM

Thực nghiệm chạy toàn bộ pipeline MedCLIP-SAMv2 trên bốn bộ dữ liệu (Breast US, Brain MRI, Lung X-ray, Lung CT). Bảng dưới đây so sánh giá trị báo cáo trong bài (paper) với kết quả thu được trên bản triển khai hiện tại cho zero-shot (ZS) và weakly-supervised (WS, nnUNet trên pseudo-labels).

Bảng tóm tắt kết quả (DSC %):

Dataset	ZS DSC (paper)	ZS DSC (ours)	WS DSC (paper)	WS DSC (ours)
Breast US	77.76%	5.17%	78.87%	5.61%
Brain MRI	76.52%	4.86%	80.03%	5.01%
Lung X-ray	75.79%	50.01%	80.77%	49.62%
Lung CT	80.38%	7.93%	88.78%	9.04%

Nhận xét chính:

- Hiệu năng tốt nhất đạt được trên **Lung X-ray**, cả zero-shot lẫn weakly-supervised đều ~50% DSC — cho thấy pipeline tạo được pseudo-label hữu dụng trên modality này.
- Ba bộ dữ liệu còn lại (Breast US, Brain MRI, Lung CT) có DSC rất thấp ($\approx 4-9\%$), cho thấy pseudo-labels do M2IB $\rightarrow$ hậu xử lý $\rightarrow$ SAM sinh ra không đủ chất lượng để huấn luyện nnUNet hiệu quả trong bản triển khai này.
- Sự khác biệt lớn giữa kết quả paper và kết quả hiện tại chỉ ra rằng các thành phần tạo pseudo-label (BiomedCLIP fine-tuning, M2IB attribution, hậu xử lý) cần tối ưu thêm cho từng modality cụ thể.

Phân tích nguyên nhân khả thi:

- Saliency map kém (gần rỗng) trên Breast/Brain/CT: dẫn đến bounding box/points không chứa thông tin về tổn thương $\rightarrow$ SAM không thể tạo mask chuẩn $\rightarrow$ nnUNet học từ nhãn giả kém.
- Lung X-ray có cấu trúc vùng tổn thương rõ hơn (vùng phổi), nên M2IB dễ hội tụ và cho saliency có ý nghĩa.
- Các thông số huấn luyện (số epoch, batch size, cài đặt DHN-NCE, và quy mô tính toán giảm so với công bố gốc) có thể ảnh hưởng tới chất lượng fine-tuning và do đó ảnh hưởng chuỗi tiếp theo.

IX. HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN

A. Các hạn chế hiện tại

Mặc dù đạt được những kết quả vô cùng khả quan, thực nghiệm trên hệ thống cục bộ cũng chỉ ra một số điểm nghẽn kỹ thuật quan trọng:

- Yêu cầu tài nguyên phần cứng lớn:** Việc sử dụng SAM với backbone ViT-H (ViT-Huge) đòi hỏi lượng bộ nhớ VRAM lớn, khiến mô hình khó triển khai trên các thiết bị đầu cuối y tế cấu hình thấp hoặc các thiết bị di động tại thực địa.
- Tốc độ suy luận (Inference Speed) còn chậm:** Quy trình xử lý qua hai mô hình lớn độc lập (BioMedCLIP sinh embedding và SAM giải mã mask) cộng thêm bước trung gian tính toán tối ưu hóa Information Bottleneck của M2IB làm tăng độ trễ (latency) trên mỗi ảnh, chưa đáp ứng được điều kiện phân đoạn thời gian thực (Real-time Inference) trong các ca phẫu thuật hoặc nội soi trực tiếp.

B. Hướng phát triển trong tương lai

Để khắc phục các nhược điểm này và mở rộng biên giới nghiên cứu, các hướng đi tiếp theo được đề xuất:

1. **Tích hợp Mô hình Ngôn ngữ Lớn (LLM) đa phương thức:** Sử dụng các mô hình ngôn ngữ lớn chuyên y tế (như Med-PALM hoặc LLaVA-Med) để tự động hóa việc sinh các đoạn văn bản gợi ý (Text Prompt) chuyên sâu, giàu ngữ cảnh giải phẫu từ hồ sơ bệnh án điện tử, thay vì phụ thuộc vào các từ khóa đơn lẻ do kỹ sư nhập thủ công.
2. **Tối ưu hóa thời gian thực (Realtime Optimization):** Áp dụng các kỹ thuật nén mô hình như lượng tử hóa trọng số (Quantization - INT8/FP16), chưng cất tri thức (Knowledge Distillation) từ kiến trúc ViT-H xuống các phiên bản SAM nhỏ gọn hơn (như MobileSAM hoặc FastSAM) nhằm giảm độ trễ xử lý mà vẫn bảo toàn độ chính xác phân đoạn cơ bản.

X. KẾT LUẬN

- **Tóm tắt công trình:** Báo cáo trình bày một pipeline ba giai đoạn (1) fine-tune BiomedCLIP, (2) trích attribution M2IB → hậu xử lý → tinh chỉnh bằng SAM để tạo pseudo-labels, và (3) huấn luyện nnUNet yếu giám sát trên pseudo-labels thu được. Repo cung cấp mã nguồn để chạy end-to-end và đánh giá bằng DSC/NSD.
- **Kết quả chính:** Trong bản triển khai hiện tại, chỉ **Lung X-ray** đạt hiệu năng trung bình chấp nhận được ($\approx 50\%$ DSC); các bộ dữ liệu còn lại (Breast US, Brain MRI, Lung CT) có DSC rất thấp ($\approx 4-9\%$). Điều này cho thấy pipeline khả dụng nhưng chưa đủ tổng quát hóa trên nhiều modality.
- **Nguyên nhân chủ yếu:** Chất lượng pseudo-label thấp (saliency gần rỗng hoặc nhiễu) do hạn chế trong fine-tuning BiomedCLIP, thiết lập M2IB, và chiến lược hậu xử lý; các khác biệt triển khai và quy mô huấn luyện so với bài gốc cũng góp phần.
- **Ý nghĩa:** Phương pháp tổng thể (CLIP-based attribution + SAM + nnUNet) là một hướng khả thi để tận dụng tín hiệu ngôn ngữ-hình ảnh cho phân đoạn y tế khi pseudo-label có chất lượng tốt. Tuy nhiên, hiệu quả thực tế phụ thuộc mạnh vào từng modality và các bước trung gian.

Thử nghiệm cho thấy MedCLIP-SAMv2 tiềm năng ứng dụng, đặc biệt trên Chest X-ray; tuy nhiên BUSI, Brain MRI và Lung CT hiện vẫn đạt hiệu năng thấp do chất lượng pseudo-label, nên cần cải thiện fine-tuning, attribution và hậu xử lý trước khi khẳng định công cụ này đáng tin cậy cho ứng dụng lâm sàng rộng rãi.

TÀI LIỆU THAM KHẢO / THƯ MỤC THAM CHIẾU

1. Koleilat, T., Asgariandehkordi, H., Rivaz, H., & Xiao, Y. (2024). *MedCLIP-SAMv2: Towards Universal Text-Driven Medical Image Segmentation*. arXiv preprint arXiv:2409.19483v3. URL gốc: <https://arxiv.org/abs/2409.19483>
2. Kho lưu trữ mã nguồn thực nghiệm cá nhân: <https://github.com/Blackdarked/MedCLIP-SAMv2>
3. Zhang, S., et al. (2023). *Large-scale bi-modal pre-training for public medical imaging and text* (BioMedCLIP). Microsoft Research.
4. Kirillov, A., et al. (2023). *Segment anything*. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) (SAM).